

Detecção de Fraudes em Transações Financeiras Utilizando Análise de Grafos utilizando PageRank e Neo4J

Alexon Amaro de Oliveira¹, Nicola Defonte¹, Félix Garcia¹,

¹Pós-Graduação em computação Aplicada

Instituto de Ciências Exatas, Universidade de Brasília, Campus Universitário Darcy Ribeiro Instituto Central de Ciências

RESUMO

A crescente sofisticação das fraudes em transações financeiras online representa um dos maiores desafios para instituições bancárias e plataformas digitais. Táticas fraudulentas evoluem continuamente, o que inviabiliza o uso exclusivo de modelos tradicionais baseados em regras estáticas e consultas relacionais. Neste contexto, este estudo propõe uma abordagem híbrida para a detecção em larga escala, integrando o algoritmo PageRank Personalizado (PPR) e os recursos analíticos nativos do banco de dados orientado a grafos Neo4J. A partir de uma base contendo mais de 2 milhões de registros com, as transações foram modeladas como grafos direcionados que conectam entidades como usuários, cartões, endereços IP, dispositivos, produtos e localizações geográficas. A proposta une análise relacional e algoritmos de centralidade estrutural (PPR), além de técnicas como detecção de comunidades, propagação de rótulos e análise de vizinhança expandida. Os resultados apontam para uma melhora significativa na detecção de estruturas complexas associadas à fraude, com redução de falsos positivos e identificação de cadeias transacionais anômalas. O modelo mostra-se escalável, aplicável em ambientes de produção e com potencial para integração em pipelines de monitoramento em tempo real.

Palavras-chave: detecção de fraude, Neo4J, PageRank personalizado, análise de grafos, sistemas financeiros

1. INTRODUÇÃO

A fraude em transações financeiras online constitui um problema de escala global, com impactos econômicos relevantes tanto em países desenvolvidos quanto em economias emergentes. Segundo a Association of Certified Fraud Examiners (ACFE, 2022), perdas corporativas com fraudes representam, em média, 5% do faturamento global das organizações. No setor de meios de pagamento, estima-se prejuízo de US\$ 34,36 bilhões em 2022, somente com fraudes envolvendo cartões de crédito e débito. Embora o valor absoluto das perdas venha crescendo ao longo dos anos, com projeções que superam US\$ 49 bilhões até 2030, observa-se uma redução gradual no índice de perdas por volume transacionado, o que indica uma maior eficácia relativa dos mecanismos de controle. Nos Estados Unidos, por exemplo, concentrou-se cerca de 38% das perdas globais em 2022. O cenário europeu também exige atenção: o European Banking Authority (2024) reportou perdas superiores a € 633 milhões apenas no primeiro semestre de 2023. Já países como Canadá, Austrália e Reino Unido apresentam prejuízos anuais superiores a US\$ 500 milhões, evidenciando que a fraude financeira digital permanece como um fenômeno transnacional, dinâmico e persistente.



Gráfico 1 – Série histórica de perdas por fraude no mercado global de cartões de crédito.

Fonte: Association of Certified Fraud Examiners (2022), com adaptações

No Brasil, o cenário não é menos preocupante. Dados da Serasa Experian indicam que, apenas no primeiro trimestre de 2025, foram registradas 1,87 milhões de tentativas de fraude em instituições financeiras e operadoras de cartão de crédito, somando um prejuízo estimado em R\$ 15,7 bilhões. Em janeiro do mesmo ano, foram detectadas 1,24 milhão de tentativas de fraude, o que equivale a uma tentativa a cada 2,2 segundos. O setor de bancos e cartões foi o principal alvo, concentrando 52,5% dos ataques. A distribuição geográfica das ocorrências revela uma concentração expressiva no estado de São Paulo (338 mil), seguido por Rio de

Janeiro (115 mil) e Minas Gerais (108 mil). Em termos regionais, o Sudeste lidera com 1,8 milhão de registros, enquanto estados como Rondônia, Bahia e Goiás apresentam índices percentuais acima da média nacional, sugerindo uma evolução nas estratégias de fraude e uma disseminação mais ampla pelo território nacional (Serasa, 2023).




Gráfico 2 – Tentativas de fraude em alguns estados. Azul representa os estados com dados absolutos. Em laranja tem-se os estados com taxas percentuais acima da média nacional.

Fonte: Serasa 2022 com adaptações.

Esse panorama evidencia as limitações dos modelos tradicionais de detecção de fraudes, que se baseiam em regras determinísticas, análises tabulares ou classificações lineares. Tais abordagens apresentam alta taxa de falsos positivos, dificuldade de adaptação a novas estratégias adversariais e ineficiência na identificação de padrões complexos e distribuídos. As estratégias contemporâneas de fraude incluem o uso de múltiplas contas interconectadas, dispositivos clonados, manipulação de localização geográfica, e até mesmo transações aparentemente legítimas, mas articuladas em estruturas ocultas. Essas características exigem soluções analíticas capazes de capturar a complexidade relacional e dinâmica das redes transacionais.

Para enfrentar esses desafios, este trabalho propõe uma abordagem híbrida baseada em análise de grafos, utilizando o algoritmo PageRank Personalizado (PPR) em conjunto com os recursos nativos do banco de dados orientado a grafos Neo4J. O PPR, amplamente utilizado na análise de influência em redes (Page & Brin, 1998), é aqui adaptado para estimar a centralidade de entidades como usuários, cartões, endereços IP e dispositivos, levando em conta seu papel estrutural em redes transacionais (Vlasselaer, et al., 2015).

A integração do PPR com ferramentas como detecção de comunidades (Louvain), Label Propagation e análise de

vizinhança permitem identificar não apenas transações suspeitas isoladas, mas também agrupamentos anômalos com alta coesão estrutural. Espera-se que esta combinação supere as limitações dos métodos lineares tradicionais, oferecendo maior acurácia e explicabilidade no processo de detecção de fraudes financeiras.

2. TRABALHOS RELACIONADOS

2.1. O algoritmo Pagerank

O algoritmo PageRank - PR, introduzido por Page e Brin (1998), foi originalmente concebido para ordenar páginas na web com base em sua relevância estrutural. Nesse modelo, cada página é representada como um nó e cada hiperlink como uma aresta direcionada entre nós. A ideia é que páginas importantes tendem a ser referenciadas por outras páginas igualmente relevantes, estabelecendo assim uma hierarquia de influência. A pontuação atribuída a cada página reflete essa dinâmica: links provenientes de páginas com alto PR aumentam proporcionalmente a importância das páginas de destino. Essa lógica fundamenta a avaliação da confiabilidade e visibilidade das páginas na rede, baseando-se puramente em conectividade topológica.




Figura 1 - Representação do Algoritmo PageRank em uma Rede de Páginas Web: Fonte: Google PageRank Explained for SEO Beginners com adaptações.

Do ponto de vista matemático, o PR pode ser interpretado como um processo de Markov estacionário, em que o objetivo é calcular a distribuição de probabilidade de um “navegador aleatório” visitar determinada página após um número indefinido de passos. A transição entre páginas é influenciada pela quantidade de links recebidos e pela importância de suas origens, configurando um mecanismo que premia a interconectividade qualitativa. Assim, páginas que são apontadas por outras com elevada centralidade tornam-se mais “confiáveis” dentro do grafo, mesmo que não possuam necessariamente um número elevado de conexões.

Para uma cadeia de Markov, equação (1), o mais comum é considerar a estacionariedade em distribuição, ou seja:

A distribuição de probabilidade sobre os estados permanece constante ao longo do tempo, sendo chamada de distribuição estacionária π , que satisfaz:

$$\pi = \pi P$$

onde,

- π é o vetor de probabilidades estacionárias (por exemplo, $\pi = \pi_1, \pi_2, \dots, \pi_n$).
- P é a matriz de transição da cadeia (onde P_{ij} representa a probabilidade de ir do estado i para o estado j).

$$\begin{aligned} P(X_{t+1} = x | X_t = x_t, X_{t-1} = x_{t-1}, \dots, X_0) = \\ = P(X_{t-1} = x | X_t = x_t) \end{aligned} \quad (1)$$

Uma cadeia de Markov terá uma distribuição estacionária se for:

- Irredutível: todos os estados se comunicam (é possível ir de qualquer estado para qualquer outro).
- Aperiódica: o sistema não entra em ciclos rígidos.
- Recorrente positiva: o tempo esperado para retornar a um estado é finito.

Suponha uma cadeia com dois estados A e B , e a seguinte matriz de transição:

$$P = \begin{bmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{bmatrix}$$

Deseja-se encontrar $\pi = [\pi_A, \pi_B]$ / $\pi = \pi P$ e $\pi_A + \pi_B = 1$ ou seja

$$\begin{cases} \pi_A = 0.8\pi_A + 0.4\pi_B \\ \pi_B = 0.2\pi_A + 0.6\pi_B \\ \pi_A + \pi_B = 1 \end{cases} \Rightarrow \begin{cases} 0.6\pi_B = 0.2\pi_A \\ \pi_A + \pi_B = 1 \end{cases}$$

$$\pi_B = \frac{1}{2}\pi_A$$

substituindo,

$$\begin{aligned} \pi_A + \pi_B &= 1 \\ \pi_A + \frac{1}{2}\pi_A &= 1 \\ \frac{3}{2}\pi_A &= 1 \\ \pi_A &= \frac{2}{3} \quad \pi_B = \frac{1}{3} \end{aligned}$$

O valor de PageRank de um nó i , denotado por $PR(i)$, é determinado pela seguinte equação iterativa:

$$PR(i) = \frac{1-d}{N} + d \left(\sum_{j \in M(i)} \frac{PR(j)}{L(j)} \right) \quad (2)$$

onde,

- d é o fator de amortecimento (tipicamente $d = 0.85$), representando a probabilidade de o navegador seguir um link ao invés de pular para uma página aleatória;
- N é o número total de nós no grafo,
- $M(i)$ é o conjunto de páginas que apontam para o nó i ;
- $L(j)$ é o número de links saindo do nó j .

A iteração prossegue até que os valores de PageRank converjam para um estado estacionário, representando a distribuição de importância de cada nó dentro da rede.

Este modelo assume que um usuário pode seguir aleatoriamente um link em qualquer página ou decidir, com uma certa probabilidade $1-d$, ir para uma página aleatória da web. O PageRank de uma página é calculado iterativamente até que o sistema de equações se estabilize.

O algoritmo mostrou-se extremamente eficaz em contextos web, mas sua estrutura matemática é versátil o suficiente para ser adaptada a outros domínios. Em especial, sua aplicação em redes financeiras tem gerado avanços significativos na detecção de fraudes, ao identificar nós centrais em cadeias transacionais (Gleich, 2014; Vlasselaer, et al., 2015).

Além disso, Vincent D. Blondel (Blondel, et al., 2008) apontam que a combinação de PageRank com algoritmos de detecção de comunidades facilita a identificação de redes de fraude, ou seja, grupos de transações interconectadas que podem indicar atividades fraudulentas.

A função delta de Kronecker, denotada por δ_{ij} , é uma função discreta definida sobre dois índices inteiros i e j , comumente utilizada em matemática, física e engenharia para representar identidade entre índices.

$$\delta_{ij} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$$

ou seja, a função vale 1 quando os índices são iguais e 0 quando são diferentes.

Tabela 1 - Comparação entre a Função Delta de Kronecker e a Função Delta de Dirac

Função	Domínio	Valor	Uso principal
$\delta_{ij} =$	$\mathbb{Z} \times \mathbb{Z}$	$1, \text{ se } i = j$ $0, \text{ se } i \neq j$	Somatórios, álgebra linear, ortogonalidade discreta
$\delta(x)$	$\mathbb{R}$	$\infty, \text{ em } x = 0$ $\int_{-\infty}^{\infty} \delta(x) dx = 1$	Integrais, convoluções, análise de sinais, distribuições

Fonte: Mathematical Methods for Physicists, 7ª Ed. *Special Functions*

Nos últimos anos, o PR foi aplicado com sucesso em redes não convencionais, como redes sociais e redes financeiras. Uma das maiores inovações foi a utilização desse modelo na detecção de fraudes, especialmente em transações financeiras (PARK, et al., 2019; Azarm, et al., 2024). A capacidade de identificar nós centrais em grafos de transações e associá-los a comportamentos anômalos tornou o PR uma ferramenta eficaz para analisar fraudes de cartões de crédito e fraudes organizadas.

O Personalized PageRank (PPR) é uma extensão do algoritmo PageRank tradicional, em que o vetor de reinício (seed vector) é configurado para favorecer certos nós iniciais com maior probabilidade. Em vez de assumir uma distribuição uniforme de transição entre todos os nós do grafo, o PPR injeta viés estrutural em pontos específicos da rede — como entidades já identificadas como fraudulentas —, redistribuindo as pontuações com base na proximidade semântica e topológica desses nós. Isso o torna especialmente adequado para problemas de detecção de anomalias locais, como fraudes financeiras emergentes.

Personalized PageRank (PPR) usado para *semente de fraude*

$$\vec{p} = (1 - d) \cdot \vec{S} + d \cdot W_p^T \vec{p} \quad (3)$$

Onde

- $\vec{S}$ - Vetor de preferências (ex.: transações já confirmadas como fraudes)
- W - Matriz de transição normalizada
- $\vec{p}$ - Vetor de PageRank personalizado

A equação fundamental do PPR pode ser expressa como:

$$r = (1 - \alpha) \cdot v + \alpha \cdot P^T \cdot r \quad (4)$$

- r é o vetor de PageRank personalizado resultante;
- v é o vetor de preferência, configurado para dar maior peso aos nós previamente identificados como suspeitos ou fraudulentos;
- P^T é a transposta da matriz de transição estocástica do grafo;
- $\alpha \in [0,1]$ é o fator de amortecimento (típico $\alpha = 0,85$) que equilibra entre exploração e reinício.

Conforme Gleich (2014), essa configuração orientada permite detectar nós com alta centralidade relativa ao conjunto semente, mesmo que não estejam diretamente conectados. Em redes de fraude, isso equivale a identificar cartões clonados, usuários associados a múltiplas fraudes, ou dispositivos compartilhados entre transações suspeitas.

PARK et al. (2019) demonstram que o PPR pode ser usado para priorizar entidades em grafos de risco, reduzindo significativamente o espaço de busca em grandes volumes de dados. Azarm et al. (2024) mostram que o PPR supera algoritmos não personalizados em grafos financeiros reais, ao destacar

comunidades latentes e relações ocultas em estruturas de fraude adaptativa.

A aplicação do PPR nas redes de transações, permite identificar os nós mais influentes, que funcionam como pontos centrais de propagação de fraudes.

O uso do PPR como mecanismo de expansão estrutural de risco em redes transacionais representa um avanço significativo frente às abordagens tradicionais. Ele permite inferência indireta de risco, mesmo em contextos com rotulagem escassa, e é particularmente eficaz na detecção precoce de fraudes organizadas, lavagem de dinheiro e autofraudes simuladas por múltiplos agentes.

A Figura 2 apresenta a rede de transações com pesos de PPR. É possível observar a concentração de influência em determinados cartões e usuários, o que orienta a priorização de investigação sobre esses elementos.




Figura 2 - Distribuição da Centralidade via PageRank na Rede Transacional.

Fonte: Elaborado pelos autores com base em dados extraído através do software Neo4J com aplicações de PageRank (2025).

A Figura 2 representa a aplicação do algoritmo de PPR sobre uma rede transacional contendo diferentes tipos de nós: usuários (U), cartões (C), transações (T), produtos (P) e dispositivos (D). As setas indicam o sentido da relação, e a coloração varia conforme o valor de centralidade atribuído pelo algoritmo.

No contexto de fraude, um usuário com PPR elevado, como o U1, indica centralidade elevada, pois está conectado a múltiplos dispositivos, cartões e transações suspeitas ou é ponto comum de propagação em diversas rotas transacionais.

Essa abordagem é útil para:

- Detectar hubs ocultos de fraude (usuários ou cartões compartilhados),
- Priorizar investigações com base na influência dos nós,
- Alimentar modelos de aprendizado supervisionado com features derivados da centralidade.

2.2. A modelagem Neo4J

Neo4J é um banco de dados orientado a grafos que armazena informações como uma rede de nós e arestas direcionadas, ambas dotadas de propriedades. Essa estrutura é particularmente adequada para modelar transações financeiras, onde múltiplas entidades como usuários, cartões, dispositivos e produtos estão interligadas por relações que podem indicar padrões suspeitos.




Figura 3 – Modelagem de Entidades Transacionais em Neo4J com Suporte Teórico.
Fonte: os autores (2025)

A Figura 3 representa a estrutura básica da modelagem em grafos implementada no Neo4J, com entidades centrais como Usuário, Cartão, Produto e Dispositivo conectadas por relações transacionais. Essa arquitetura é sustentada por fundamentos de Teoria dos Grafos, Álgebra Linear e Otimização Computacional, possibilitando análises estruturais avançadas para detecção de fraudes.

- PageRank e Personalized PageRank (centralidade);
- Louvain (modularidade e comunidades);
- Label Propagation (influência e difusão);
- Weakly Connected Components (segmentação estrutural).

A maximização de Q leva à identificação de agrupamentos com alta densidade interna e baixa conectividade externa, o que é típico em células organizadas de fraude.

Para detecção em comunidades

$$Q = \frac{1}{2m} \cdot \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \cdot \delta(c_i c_j) \quad (5)$$

onde

- A_{ij} é a matriz de adjacência
- k_i e k_j são os graus dos nós i e j
- m é o número total de arestas
- $\delta(c_i c_j)$ é a função delta de Kronecker que vale 1 se os nós estão na mesma comunidade

Por exemplo, o algoritmo PPR no Neo4j Graph Data Science (GDS) calcula a pontuação $PR(j)$ equação (2), de cada nó em um grafo baseado na influência acumulada dos vizinhos, de forma idêntica ao modelo de PR (Page & Brin, 1998), mas estendido para contextos que vão além da web (Azarm, et al., 2024).

O uso do Neo4j na detecção de fraudes tem sido amplamente documentado em estudos e casos de sucesso. Em Prusti (Prusti, Das, & Rath, 2021) propõe o uso do Neo4j para modelar transações financeiras como um grafo e detectar fraudes através da análise de conexões e padrões de transações suspeitas. Jamardarr (2022) relata sobre aplicação do Neo4j com algoritmos de aprendizado de máquina para identificar transações fraudulentas em bancos. Sua análise destaca como a estrutura de grafo facilita a análise de redes complexas de transações, permitindo identificar nós centrais, como cartões ou usuários comprometidos, que frequentemente aparecem em fraudes organizadas (Jamardarr & Chavan, 2022).

Neo4j trabalha sobre uma ontologia de dados com:

- Nódulos ($v \in V$): entidades (ex: usuários, cartões, transações, dispositivos, etc)

- Rótulos de tipos: permitem filtragem e agrupamento semântico
- Arestas direcionadas $e_{ij} \in E$: relações transacionais
- Propriedades de arestas: valores, datas, frequência, risco, localização

Essas entidades são convertidas em vetores/matrizes ao aplicar algoritmos (como PageRank), ou em agrupamentos probabilísticos ao aplicar Louvain.

A modelagem com Neo4J oferece uma estrutura expressiva, escalável e adaptável às exigências da detecção de fraudes financeiras modernas. Ao viabilizar a aplicação de algoritmos como PageRank Personalizado, Louvain e Label Propagation diretamente sobre grafos transacionais, o banco permite que padrões ocultos de comportamento anômalo sejam revelados com maior precisão e rapidez do que em arquiteturas relacionais convencionais.

3. METODOLOGIA

A metodologia proposta neste estudo está estruturada em quatro etapas principais, visando detecção de fraudes em transações financeiras, com uso de grafos para modelar as relações entre entidades.

3.1. Preparação e normalização da base de dados

Para o desenvolvimento do experimento, foi utilizada uma base sintética contendo 2 milhões de registros de transações financeiras de uma plataforma de e-commerce entre janeiro de 2023 e dezembro de 2024. Os dados foram obtidos no formato .csv, refletindo ambientes que priorizam escalabilidade horizontal e flexibilidade de schema, características comuns em sistemas que lidam com grandes volumes de transações (Robinson, Webber, & Eifrem, 2015).

3.2. Pré-processamento e modelagem relacional

A estrutura heterogênea dessa base apresentou desafios significativos à construção de um grafo de relacionamento confiável, uma vez que entidades como CPF, IP ou nome do produto apareciam de forma redundante ou não normalizada. Conforme explica (Kamber & Han, 2022), a qualidade dos dados é determinante para o sucesso de qualquer análise baseada em mineração de dados, especialmente em arquiteturas orientadas a grafos.

Dessa forma, foi realizada uma etapa de pré-processamento, seguida da normalização dos dados, com os seguintes objetivos:

- Eliminar duplicações (ex.: múltiplos registros para o mesmo CPF);
- Tratar valores nulos e inconsistentes (datas, categorias, bandeiras);
- Uniformizar campos categóricos, como produto, localização e dispositivos;
- Converter a estrutura para formato relacional ACID, com tabelas como usuários, cartões, produtos, dispositivos, bancos e categorias.

A base transacoes.csv contém os principais atributos associados às transações realizadas, tais como:

- Identificação única da transação (id_transacao);
- Dados do usuário (CPF, IP, geolocalização, dispositivo, histórico);
- Informações do cartão (número do cartão, bandeira, banco emissor, validade,);

- Produtos adquiridos (categoria do produto, tipo de produto, quantidade produto, valor do produto);
- Indicadores de risco e status da transação;
- Métodos de autenticação e tipo de dispositivo;
- Data/hora, valor total, e status da operação (autorizada, negada, estornada etc.).



Figura 4 – Normalização de Dados: Da Base NoSQL ao Modelo Relacional PostgreSQL.

Fonte: os autores (2025)

A Figura 4 representa visualmente como os dados brutos são organizados e distribuídos em tabelas e normalizado, para remover redundâncias e garantir integridade referencial.




Figura 5 – Normalização do banco de dados relacional

Fonte: os autores (2025)

Após a normalização dos dados foi possível construir views otimizadas para análises com algoritmos como PPR, Label Propagation e Louvain, aplicados sobre o banco de dados relacional e exportados para o Neo4J.

3.3. Anonimização e proteção de dados

Dado o contexto sensível das informações, foram implementada uma política rigorosa de anonimização dos dados sensíveis, em conformidade com a Lei Geral de Proteção de Dados (LGPD) (Congresso Nacional, 2018)

- Todos os identificadores pessoais (ex.: CPF, nome) foram substituídos por códigos aleatórios únicos;
- Novos números de cartões foram gerados de forma sintética, mantendo as bandeiras originais apenas para fins estatísticos;
- Endereços foram desassociados de nomes reais, sendo vinculados exclusivamente por código postal, bairro e cidade.

Essa abordagem garante que a análise dos dados, mesmo quando combinada com algoritmos sensíveis, não comprometa a identidade dos usuários ou entidades envolvidas, mantendo o caráter ético e seguro do experimento.

4. ELABORAÇÃO DO GRAFO E EXPORTAÇÃO PARA NEO4J

Ao contrário de abordagens supervisionadas convencionais, este estudo não parte de rótulos previamente conhecidos que indiquem diretamente transações fraudulentas. Em vez disso, baseia-se na extração de padrões estruturais a partir da topologia da rede, por meio de metadados transacionais. A aplicação de algoritmos como Louvain, Label Propagation e Personalized PageRank (PPR)

permite identificar comunidades densamente conectadas, entidades recorrentes e interações suspeitas que emergem da estrutura relacional dos dados.

A partir dessas inferências, calculam-se métricas de centralidade, modularidade e influência estrutural, que permitem estimar a recorrência de comportamento anômalo e a conectividade de risco entre os nós (usuários, cartões, IPs, dispositivos, produtos). Esses valores são utilizados para atribuir um escore de risco a cada entidade, refletindo sua probabilidade de envolvimento em comportamento fraudulento. Tais escores podem ser explorados em análises supervisionadas ou semissupervisionadas, servindo como base para a validação de clusters suspeitos e a detecção preditiva de fraudes.




Figura 6 – Pipeline de Análise de Fraudes com Base em Grafos.

Fonte: os autores (2025)

A Figura 7 ilustra o pipeline adotado neste estudo. Inicialmente, os dados transacionais são estruturados e normalizados em um banco relacional PostgreSQL. Em seguida, os registros são exportados para o ambiente Neo4J, onde são convertidos em uma estrutura de grafo com nós e arestas representando entidades e relações transacionais. A partir dessa modelagem, algoritmos como PPR, Louvain e Label Propagation são aplicados diretamente sobre a rede para mensurar a relevância estrutural dos nós.

Com os escores atribuídos às entidades, procede-se à comparação com inferências comportamentais e, quando possível, com validações externas. Embora não haja *labels* explícitos na base original indicando fraude, o cruzamento entre os padrões detectados, o contexto transacional e os agrupamentos emergentes viabilizam a avaliação da performance dos métodos empregados. As métricas utilizadas para essa validação incluem precisão, recall, F1-score, acurácia e AUC (área sob a curva ROC).

4.1. Estruturas do grafo e Entidades Centrais

Com base na modelagem adotada, o algoritmo PPR foi aplicado para medir a importância estrutural de cada nó, priorizando entidades suspeitas com base em um vetor de semente contendo transações já marcadas como fraudulentas (PARK, et al., 2019; Gleich, 2014).

A estrutura resultante permitiu a aplicação dos algoritmos PageRank Personalizado, Louvain e Label Propagation diretamente no ambiente GDS do Neo4J. Cada relação foi acompanhada de atributos relevantes, como data da conexão, valor envolvido, risco estimado e status da transação.

- **Nódulos:** Usuário, Cartão, IP, Produto, Dispositivo, Transação;
- **Arestas:** USOU_CARTAO, ACESSOU_DE_IP, COMPROU_PRODUTO, ENTREGOU_EM, UTILIZOU_DISPOSITIVO.

Na Figura 7 observa-se que a metodologia adotada garantiu não apenas confiabilidade e integridade na estrutura do grafo, mas também preparou o ambiente ideal para aplicação de algoritmos robustos de análise topológica e detecção de comunidades. O rigor

na preparação dos dados se mostrou fundamental para assegurar a validade e interpretabilidade dos resultados subsequentes.




Figura 7 – Grafo das relações transacionais para detecção e fraude. Fonte: Elaborado pelos autores com base em dados extraído através do software Neo4J com aplicações de PageRank (2025).

Na Figura 8 traz uma rede transacional densa, composta por múltiplos nós e arestas direcionadas, representando interações entre entidades do sistema financeiro (usuários, cartões, dispositivos, IPs, produtos e transações). A complexidade e a densidade das conexões indicam uma estrutura realista de interações em larga escala.




Figura 8 – Comunidades Transacionais Detectadas com Louvain em Rede Complexa. O grafo mostra a estrutura de conexões entre entidades da base de transações. Fonte: Elaborado pelos autores com base em dados extraído através do software Neo4J com aplicações de PageRank (2025).

os elementos representam

- Nódulos coloridos: Cada nó representa uma entidade única do sistema (como um cartão de crédito, um usuário, ou um IP).
- Arestas: Indicadores de relações transacionais entre essas entidades (uso compartilhado, transações repetidas, reutilização de IP, etc.).
- Cores: As cores representam comunidades detectadas automaticamente pelo algoritmo de Louvain, com base em alta modularidade. Cada cor identifica um agrupamento de entidades com forte interconectividade interna.

4.2. Agrupamentos Modulares e comunidades de risco

A Figura 9 ilustra os resultados parcial, obtidos a partir da aplicação do algoritmo de Louvain sobre uma subrede transacional,

representando conexões entre usuários (U), cartões (C), dispositivos (D) e transações (T). O objetivo é identificar duas comunidades de nós conectados, que potencialmente revelam padrões de comportamento suspeito, compartilhamento de entidades ou fraudes organizadas.




Figura 9 – Rede Transacional com Agrupamentos Potenciais. Fonte: Elaborado pelos autores com base em dados extraído através do software Neo4J com aplicações de PageRank (2025).

A comunidade azul agrupa o usuário U1, seu cartão C1, transação T1 e dispositivo D1, indicando um cluster de comportamento individualizado.

A comunidade laranja conecta U2, C2, T2, D2, e também P1, T3, mostrando uma rede mais entrelaçada, sugerindo compartilhamento de elementos um indicio de risco.

A Figura 10 apresenta visualmente esse agrupamento, onde observam-se duas comunidades principais. composta por seis tipos de entidades: usuários (U), cartões (C), transações (T), dispositivos (D), produtos (P) e endereços IP (IP). As ligações entre os nós refletem interações diretas como uso de cartões, dispositivos compartilhados, ou mesmo reutilização de IPs. Esses grupos indicam padrões de comportamento colaborativo ou coordenado, muitas vezes presentes em fraudes organizadas.




Figura 10 – Grafo de entidades com agrupamentos detectados. Fonte: Os autores - Imagem gerada a partir do software Neo4J (2025).

Essa representação favorece a aplicação de algoritmos como o de Louvain, que detectam comunidades com alta modularidade, revelando núcleos estruturais relevantes para a análise de fraudes. Por exemplo, padrões de compartilhamento de cartões, IPs e dispositivos entre usuários podem indicar comportamentos coordenados, autofraudes ou tentativas de mascarar identidades.

A construção dessa rede, com tipificação clara dos nós e das relações, permite não apenas a visualização intuitiva dos agrupamentos, mas também a sua quantificação estrutural por métricas de centralidade e modularidade, servindo como insumo para alertas automáticos em sistemas de monitoramento de risco.

Complementarmente, outra abordagem explorada foi o algoritmo Label Propagation, que utiliza a conectividade local entre os nós

para propagar rótulos de influência ao longo da rede. Ao contrário do Louvain, que maximiza modularidade, essa técnica é particularmente eficaz na detecção rápida de comunidades em ambientes de transações dinâmicas, permitindo identificar agrupamentos temporários ou interações voláteis.

Adicionalmente, a natureza não supervisionada e adaptativa do Label Propagation revelou subestruturas com vínculos fracos, porém recorrentes, característicos de redes de fraude distribuídas. Essa capacidade de expor células difusas de influência é fundamental para detectar comportamentos anômalos que evoluem ao longo do tempo, dificultando a rastreabilidade por métodos convencionais (Azarm, et al., 2024).

Tabela 2 – Na amostra de dados foram identificados grupos de entidades com alta conectividade interna detectados por Louvain. A Comunidade 1 se destaca como estrutura crítica associada a fraude

Comunidade	Número de Nós	Grau Médio	Entidades Suspeitas	Fraudes Confirmadas
1	168	3.2	12	7
2	84	2.1	4	2
3	129	2.7	0	0

Fonte: os autores, com base nos dados extraídos da análise (2025)

4.3. Análise Agregada de Impacto – Perfil de usuários

Em uma análise mais aprofundada, realizada sobre um universo de 200.000 usuários, identificou-se que 18.300 usuários apresentaram fortes indícios de comportamento fraudulento ao longo do período analisado (jan/2023 – dez/2024). Isso corresponde a 9,15% do total, o que já representa um sinal de alerta considerável para qualquer sistema financeiro.




Figura 11 – Gráfico radar com indicadores de risco e impacto. Fonte: Os autores - Imagem gerada a partir do software Neo4J (2025).

A Figura 11 apresenta uma visualização em gráfico radar, destacando a distribuição relativa das variáveis de risco observadas. A convergência entre o volume de usuários suspeitos, o valor comprometido e a média de tentativas reforçam a existência de padrões estruturais de fraude.

Tabela 3 - resume os principais indicadores observados

Métrica	Valor
Total de Usuários Analisados	200.000
Usuários com Indícios de Fraude	18.300
Percentual Suspeito (%)	9,15%
Média de tentativas por usuário com comportamento anômalo	25,0
Valor Potencial Comprometido	R\$ 3.950.000,00

Fonte: os autores, com base nos dados extraídos da análise (2025)

Conforme Tabela 3 esses usuários realizaram, em média, 25 tentativas cada (com desvios dentro de clusters de repetição), totalizando 18.300 tentativas de transações suspeitas no período analisado. A estimativa do valor potencialmente maior que R\$ 3,95 milhões (no período), com destaque para transações negadas, múltiplos cartões por usuário e reuso de IPs e dispositivos.

A integração dos dados de transações com a base de cartões revelou um padrão relevante entre os 100 usuários com maior número de transações suspeitas. Todos os usuários dessa amostra operaram com três cartões diferentes de diferentes bandeiras, configurando um comportamento recorrente de multiuso e potencial compartilhamento ou multiplicação de identidades financeiras.

A análise revela uma concentração expressiva em bandeiras não tradicionais, como Discover, Nubank e American Express, com destaque para a presença combinada dessas três em diversos perfis. As bandeiras Visa, MasterCard e Elo, embora amplamente utilizadas no mercado, aparecem em proporções ligeiramente inferiores, sugerindo que fraudadores preferem emitir ou utilizar cartões de menor rastreabilidade ou com menor rigor de autenticação.

É relevante também a presença outras bandeiras menos utilizadas em aplicações regulares, mas que surgem de forma significativa em combinações com fintechs e cartões de crédito internacionais. Essas misturas podem indicar tentativas de pulverização de risco, utilizando cartões com perfis diferentes de aprovação ou aceitação em gateways distintos.

Esse comportamento está de acordo com os achados de Vlasselaer (Vlasselaer, et al., 2015) e Gleich (Gleich, 2014), que demonstram a eficácia do PageRank em detectar fraudes organizadas por meio da análise topológica da rede.




Gráfico 3 – Frequência de bandeiras entre usuários com 3 cartões. Fonte: os autores, com base nos dados extraídos da análise (2025)

O Gráfico 3 evidencia o padrão de diversificação das bandeiras utilizadas por usuários com atividade anômala elevada, caracterizando um comportamento suspeito de replicação e interposição de cartões.

Essa análise complementa a detecção topológica dos algoritmos de grafos, revelando que os nós com alta centralidade estrutural não apenas operam com múltiplos dispositivos ou IPs, mas também mantêm uma variedade de cartões com múltiplas bandeiras, possivelmente para burlar regras antifraude específicas de cada operadora.

A integração dos dados de transações com a base de cartões revelou um padrão relevante entre os 100 usuários com maior número de tentativas de efetivar compras. Todos os identificados possuíam três cartões de créditos distintos frequentemente de bandeiras diferentes, conforme Tabela 3.




Figura 12 – Perfil médio de usuários com alta atividade e múltiplos cartões.

Os autores - Imagem gerada a partir do software Neo4J (2025).

o Gráfico Radar (Figura 12) resume o perfil médio desses usuários, destacando:

- Média de 182 transações por usuário, significativamente acima da média geral da base.
- Três cartões utilizados por usuário, com bandeiras diversificadas como *Visa*, *MasterCard*, *Elo*, *Hipercard*, *American Express*, entre outras.
- Valor financeiro comprometido médio de R\$ 225 mil por usuário no período analisado.

Esse padrão é significativamente superior ao da média geral da base, o que sugere a existência de comportamentos coordenados ou automatizados, típicos de mecanismos fraudulentos. O uso de cartões com múltiplas bandeiras também pode indicar uma estratégia deliberada para mascarar a identidade financeira, dificultando o rastreamento das operações.

4.4. Benefícios preliminares observados

A aplicação de algoritmos de análise de grafos sobre os dados transacionais, mesmo em uma fase exploratória, evidenciou ganhos substanciais em relação às abordagens tradicionais baseadas em regras fixas e classificadores lineares. A capacidade do modelo gráfico de capturar conexões indiretas, padrões latentes e estruturas de relacionamento em larga escala resultou em benefícios concretos para a detecção de fraude.

Entre os principais benefícios preliminares observados:

- Identificação de estruturas de fraude por colusão: usuários, cartões e IPs interconectados em subgrafos densos foram prontamente detectados por algoritmos como PageRank Personalizado e Louvain, mesmo sem histórico rotulado de fraude;
- Redução significativa de falsos positivos: ao incorporar a topologia relacional da rede (como vizinhança, modularidade e influência estrutural), o sistema conseguiu distinguir transações isoladas de comportamentos articulados, diminuindo alertas irrelevantes;
- Visualização e interpretação de padrões anômalos: o uso de grafos permitiu representar comportamentos suspeitos por meio de componentes conectados, facilitando a interpretação por analistas humanos e sistemas de apoio à decisão;
- Integração com algoritmos supervisionados: a extração de métricas estruturais (ex.: grau, centralidade, pertença comunitária) gerou atributos enriquecidos que podem ser

utilizados em modelos supervisionados de aprendizado de máquina, potencializando análises híbridas;

- Escalabilidade e adaptabilidade: a estrutura orientada a grafos demonstrou maior resiliência à evolução dos padrões de fraude, sendo capaz de se adaptar a esquemas mais complexos e evasivos sem reconfiguração de regras.

Esses resultados reforçam a tese de que a análise de grafos representa uma evolução significativa nos mecanismos de detecção de fraudes em ambientes digitais. Trabalhos anteriores (Vlasselaer, et al., 2015; Prusti, Das, & Rath, 2021)

Tabela 4 - Métricas de Classificação dos Algoritmos - Avaliação dos algoritmos quanto à capacidade de detectar entidades envolvidas em fraude com base em rótulos reais simulados (5% de fraude).

Algoritmo	Precisão	Recall	F1 score	Acurácia	AUC
PageRank + Threshold	0.87	0.68	0.76	0.92	0.89
Louvain (rótulo por comunidade)	0.75	0.54	0.63	0.86	0.76
Label Propagation	0.69	0.51	0.59	0.83	0.68

Fonte: Os autores - Imagem gerada a partir do software Python/colab (2025).

O Gráfico 4 apresenta as curvas ROC (Receiver Operating Characteristic) para os três algoritmos aplicados à tarefa de detecção de fraude financeira com base na estrutura gráfica das transações. O algoritmo PPR com threshold demonstrou o melhor desempenho, com área sob a curva (AUC) de 0,89, evidenciando sua alta capacidade discriminativa mesmo em redes com conectividade difusa. Isso significa que o PPR consegue distinguir, com grande acurácia, transações legítimas daquelas associadas a padrões fraudulentos estruturais.

O algoritmo Louvain também apresentou desempenho satisfatório, com AUC de 0,76, especialmente na detecção de comunidades com alta densidade interna indicando grupos de usuários e cartões com comportamento colaborativo anômalo. Já o Label Propagation, por sua vez, obteve um desempenho inferior (AUC $\approx$ 0,68), o que está de acordo com estudos como os de Azarm (Azarm, et al., 2024), que apontam que esse algoritmo é sensível a ruídos topológicos e à ausência de conectividade clara entre nós. Ainda assim, sua natureza não supervisionada e propagativa o torna útil em redes em evolução ou quando há pouca rotulagem disponível.




Gráfico 4 – Curvas ROC para os algoritmos PageRank, Louvain e Label Propagation.

Fonte: Os autores - Imagem gerada a partir do software Python/colab (2025).

Esses resultados demonstram que abordagens baseadas em centralidade e influência global (como o PPR) são mais eficazes na detecção precoce de fraudes distribuídas e em cadeias ocultas de transações. Além disso, a integração desses métodos com

grafos dirigidos e modelagem semântica em bancos como o Neo4J viabiliza aplicações em tempo real com menor taxa de falsos positivos.

5. DISCURSÕES E RESULTADOS

Este estudo apresentou uma abordagem baseada em análise de grafos para a detecção de fraudes em transações financeiras, explorando a aplicação integrada de algoritmos como PageRank Personalizado (PPR), Louvain e Label Propagation, com suporte do banco de dados orientado a grafos Neo4J.

Os resultados obtidos demonstram que o uso de algoritmos de centralidade estrutural, em especial o PPR, é altamente eficaz na identificação de entidades centrais em redes transacionais, mesmo na ausência de conexões diretas com registros de fraude previamente conhecidos. A curva ROC obtida para o PPR ($AUC \approx 0,89$) confirmou sua alta capacidade discriminativa, superando os métodos baseados em detecção de comunidades ou propagação de rótulos, como Louvain ($AUC \approx 0,76$) e Label Propagation ($AUC \approx 0,68$), conforme ilustrado na **Erro! Fonte de referência não encontrada.**

A eficácia superior do PPR corrobora estudos como os de (Gleich, 2014), que destacam seu valor em redes direcionadas com comportamento anômalo distribuído. A detecção de comunidades por Louvain também se mostrou útil ao identificar agrupamentos coesos de entidades suspeitas, sugerindo possíveis células organizadas de fraude, em conformidade com as observações de (Blondel, et al., 2008). Já o desempenho mais modesto do Label Propagation está de acordo com os achados de (Azarm, et al., 2024), que observam sua maior sensibilidade à topologia da rede e à ausência de conectividade explícita.

A análise das métricas de desempenho (Tabela 4) indica que o PPR apresentou o melhor equilíbrio entre precisão (0,87) e revocação (0,68), refletindo uma baixa taxa de falsos positivos sem comprometer a detecção de fraudes reais. Essa característica é crítica em sistemas bancários, onde alertas excessivos podem comprometer a usabilidade e a credibilidade das soluções antifraude (Vlasselaer, et al., 2015).

No entanto, algumas limitações devem ser reconhecidas:

- A ausência de rotulagem completa em tempo real impõe desafios à validação supervisionada;
- A escalabilidade de algoritmos como Louvain pode se tornar restritiva em redes massivamente dinâmicas (Blondel, et al., 2008);
- A simulação com dados sintéticos, embora realistas, ainda não substitui a aplicação sobre bases reais sensíveis e reguladas (PARK, et al., 2019).

Como trabalhos futuros, pretende-se:

- Integrar os resultados dos algoritmos gráficos com modelos supervisionados (como XGBoost e redes neurais) em um ambiente híbrido;
- Implementar os algoritmos diretamente em pipelines de monitoramento em tempo real via Neo4J GDS (Prusti, Das, & Rath, 2021)
- Explorar técnicas de explainability em grafos (ex.: GNNExplainer, SubgraphX) para tornar as decisões do modelo mais transparentes para analistas humanos;
- Avaliar a aplicabilidade do modelo em domínios adjacentes, como detecção de autofraude, manipulação de contas ou lavagem de dinheiro em camadas.

A abordagem apresentada neste artigo mostra-se robusta, escalável e adaptável aos desafios contemporâneos da detecção de fraudes em ambientes financeiros digitais, oferecendo um caminho

promissor para a próxima geração de sistemas inteligentes de análise transacional.

6. CONCLUSÃO FINAL

Este estudo demonstrou que a análise de grafos como abordagem avançada para a detecção de fraudes em transações financeiras, é mais uma ferramenta para inibir ou coibir fraudes no sistema financeiro

A modelagem relacional da base de dados, conectando entidades como usuários, cartões, IPs, dispositivos e produtos, possibilitou a aplicação de algoritmos como PageRank, Louvain e Label Propagation, viabilizando a identificação de padrões ocultos, comunidades densamente conectadas e comportamentos transacionais atípicos.

A análise de mais de 2 milhões de transações, envolvendo aproximadamente 200 mil usuários únicos, revelou que 18.303 apresentaram indícios robustos de comportamento fraudulento, correspondendo a 9,15% do total. Esses usuários realizaram, em média, 25 tentativas de transações suspeitas no período (jan/2023 a dez/2024), resultando em um valor potencialmente superior a R\$ 3,95 milhões.

Dentre os padrões recorrentes, destacam-se o uso reiterado de múltiplos cartões, o reaproveitamento de IPs e dispositivos e a ocorrência de transações em horários incomuns, características compatíveis com fraudes coordenadas ou autofraudes sofisticadas.

Os achados obtidos convergem com evidências apontadas por instituições especializadas, reforçando a validade externa da abordagem adotada. Além de aumentar a acurácia na detecção de grupos estruturados de risco, a modelagem em grafos demonstrou potencial para redução significativa de falsos positivos, ao incorporar variáveis estruturais como modularidade, centralidade e vizinhança transacional.

Em síntese, a proposta apresentada mostra-se promissora tanto para a prevenção em tempo real quanto para a análise forense de fraudes, sendo adaptável a ambientes de produção com grandes volumes de dados. Estudos futuros podem integrar técnicas de aprendizado de máquina supervisionado sobre os vetores gerados pelas redes, ampliando ainda mais a capacidade preditiva e adaptativa dos sistemas antifraude.

Referências

- ACFE. (2022). Report to the Nations: 2022 Global Study on Occupational Fraud and Abuse. In ACFE (Ed.), (p. 96). Retrieved julho 12, 2025, from <https://www.acfe.com/-/media/files/acfe/pdfs/rtn/2022/2022-report-to-the-nations.pdf>
- Arfken, G. B., & Weber, H. J. (2005). *Mathematical Methods for Physicists*. Academic Press.
- Azarm, C., Acar, E., Zeelt, M., ., ., & . (2024, February 19). *arxiv.org*. Retrieved July 11, 2025, from ARVIX: <https://arxiv.org/html/2402.09495v2>
- Blondel, V. D., Guillaume, J.-L., Lambiotte, R., Lefebvre, E., ., & . (2008, July 25). Fast unfolding of communities in large networks. *US*. Retrieved July 13, 2025, from <https://arxiv.org/pdf/0803.0476>
- Congresso Nacional. (2018, agosto 14). Lei geral de proteção de dados pessoais. (E. d. congresso, Ed.) Brasília, Distrito Federal, Brasil. Retrieved julho 11, 2025, from https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm
- European Banking Authority. (2024). *2024 Report on Payment Fraud*. European Central Bank. Retrieved julho 2025

- Gleich, D. F. (2014, July 18). PAGERANK BEYOND THE WEB. Retrieved July 13, 2025, from <https://arxiv.org/pdf/1407.5107>
- Jamadarr, R. A., & Chavan, A. A. (2022, November). Bank Fraud Detection Using Neo4j and Machine Learning Algorithms. *International Journal of Research Publication and Reviews*, p. 5. Retrieved July 12, 2025, from <https://ijrpr.com/uploads/V3ISSUE11/IJRPR8211.pdf>
- Kamber, M., & Han, J. (2022). *Data Mining: Concepts and Techniques (The Morgan Kaufmann Series in Data Management Systems)* (4th ed.). Morgan Kaufmann.
- Page, L. E., & Brin, S. M. (1998, January 29). Bringing Order to the Web. Massachusetts, US. Retrieved July 13, 2025, from <http://ilpubs.stanford.edu:8090/422/1/1999-66.pdf>
- PARK, S., LEE, W., CHOE, B., LEE, S.-G., ., & . (2019, November 11). *A Survey on Personalized PageRank*. (I. Access, Ed.) Retrieved July 14, 2025, from ieeexplore.ieee.org: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=8895775>
- Prusti, D., Das, M., & Rath, S. K. (2021, May 4). Credit Card Fraud Detection Technique by Applying Graph Database Model. doi:<https://doi.org/10.1007/s13369-021-05682-9>
- Robinson, I., Webber, J., & Eifrem, E. (2015). *Graph Databases* (2nd ed.). O'Reilly.
- Serasa. (2023). *Prevenção à Fraude*. Serasa Experian. Acesso em 13 de julho de 2025, disponível em <https://www.serasaexperian.com.br/sala-de-imprensa/prevencao-a-fraude/quase-10-milhoes-de-tentativas-de-fraude-de-identidade-foram-registradas-em-2023-mostra-serasa-experian/>
- Vlasselaer, V. V., Bravo, C., Caelen, O., Eliassi-Rad, T., Akoglu, L., Snoeck, M., & Baesens, B. (2015, May 8). A novel approach for automated credit card transaction fraud. *Decision Support Systems*, p. 11. Retrieved July 12, 2025, from https://www.eliassi.org/papers/vanvlasselaer_dss2015.pdf